






ROBOTI MOBILI



Localizarea reprezintă acțiunea de **a stabili postura** (poziția și orientarea) robotului mobil (RM).


Față de roboții cu post fix, localizarea roboților mobili, are un caracter specific, pentru că postura **nu poate fi măsurată direct** ci printr-un element suplimentar denumit de ***estimator***.

În capitolul 2, s-a subliniat faptul că perturbațiile influențează predicțiile modelului, iar în capitolul 4, faptul că măsurătorile sunt influențate de zgomote. În consecință **este nevoie de o mediere** (aici filtrare) între ceea ce oferă modelul (postura estimată) și ceea ce oferă senzorii (diferitele măsurători).

# Cuprins


- *Probabilități*
- *Filtrul Bayesian*
- *Filtrul Kalman*
- *Filtrul Kalman extins*
- *Filtrul de particule*






Probabilități

1. Introducere
2. Algebra probabilităților
3. Formula lui Bayes
4. Concluzii





$$P(X) \equiv P(X = x_i) = \frac{n_i}{N} \rightarrow \frac{1}{6} \quad \text{Metoda statistică}$$


unde:  $X$  este variabila probabilistică;  $x_i$  este valoarea pe care o poate lua  $x_i = 1, \dots, 6$

$n_i$  este numărul de apariții ale valorii  $x_i$  (situații favorabile ale lui  $x_i$ );


**Aruncatul zarului.** Efectul acestei cauze (arunc un zar) poate avea 6 valori distincte. Numim efectul menționat **variabilă** probabilistică, iar **valoarea** sa (fața zarului care ne apare privirii) una din valorile  $1, \dots, 6$  care reprezintă numărul punctele de pe zar. Dacă facem acest experiment de multe ori putem observa că

**Exemplul** care urmează utilizează două zaruri, variabila probabilistică, aleasă, este suma celor două cifre ale fiecărui zar. Valoarea acestei variabile poate fi 2,...,12. De această dată, distribuția de probabilitate nu este uniformă, motiv pentru care cazinourile au introdus jocul de zaruri în portofoliul lor de încercări ludice.



|   | 1 | 2 | 3 | 4  | 5  | 6  |
|---|---|---|---|----|----|----|
| 1 | 2 | 3 | 4 | 5  | 6  | 7  |
| 2 | 3 | 4 | 5 | 6  | 7  | 8  |
| 3 | 4 | 5 | 6 | 7  | 8  | 9  |
| 4 | 5 | 6 | 7 | 8  | 9  | 10 |
| 5 | 6 | 7 | 8 | 9  | 10 | 11 |
| 6 | 7 | 8 | 9 | 10 | 11 | 12 |




$$E(X) = \sum_{i=1}^n x_i P(x_i) = 7$$




$$E(Y) = b \left( \sum_{i=5}^{10} P(x_i) \right) - kbP(4) = \frac{1}{12} (9 - k)b$$



$$\mathbf{P} \leftarrow \frac{100}{8} [Ludos] \quad \mathbf{F} \leftarrow \frac{7 \cdot 100}{8} [Ludos]$$



$$\left\{ \begin{array}{l} P(a_1) = .7 \\ P(a_2) = .3 = 1 - P(a_1) \\ P(b_1) = .6 \\ P(b_2) = .4 = 1 - P(b_1) \\ P(a_1, b_1) = .7 \cdot .6 = .42 \\ P(a_2, b_2) = .3 \cdot .4 = .12 \\ P(a_1, b_2) = .7 \cdot .4 = .28 \\ P(a_2, b_1) = .3 \cdot .6 = .18 \end{array} \right. \Rightarrow \left\{ \begin{array}{l} P(a_1, b_1) + P(a_1, b_2) = P(a_1) = .7 \\ P(a_1, b_1) + P(a_2, b_1) = P(b_1) = .6 \\ P(a_2, b_1) + P(a_2, b_2) = P(a_2) = .3 \\ P(a_1, b_2) + P(a_2, b_2) = P(b_2) = .4 \\ \sum_{i,j} P(a_i, b_j) = 1 \end{array} \right.$$




$$P(a_i \cup a_j) = P(a_i) + P(a_j)$$

dacă  $a_i, a_j$  sunt independente, adică dacă



$$P(a_i \cup a_j) = P(a_i) + P(a_j) - P(a_i \cap a_j)$$

$$P(b_j) = \sum_i P(b_j a_i)$$





$$\begin{cases} P(a_1) = \frac{2}{3} \\ P(a_2) = 1 - P(a_1) = \frac{1}{3} \end{cases}; \begin{cases} P(b_1) = \frac{2}{3} \\ P(b_2) = 1 - P(b_1) = \frac{1}{3} \end{cases}; P(a_1, b_1) = \frac{1}{3}$$

$$P(a_1, b_1) = \frac{1}{3} \neq P(a_1)P(b_1) = \frac{4}{9}$$



$$\begin{cases} P(a_1 | b_1) = \frac{\frac{1}{3}}{\frac{2}{3}} = \frac{1}{2} \\ P(a_2 | b_1) = \frac{\frac{1}{3}}{\frac{2}{3}} = \frac{1}{2} \end{cases}; P(a_1 | b_1) + P(a_2 | b_1) = 1;$$



$$\left\{ \begin{array}{l} P(a_1 | b_1) = \frac{\frac{1}{3}}{\frac{2}{3}} = \frac{1}{2} \\ P(a_2 | b_1) = \frac{\frac{1}{3}}{\frac{2}{3}} = \frac{1}{2} \end{array} \right. ; P(a_1 | b_1) + P(a_2 | b_1) = 1;$$

$$\left\{ \begin{array}{l} P(a_1, b_1) = P(b_1)P(a_1 | b_1) = \frac{2}{3} \frac{1}{2} = \frac{1}{3} \\ P(a_1, b_1) = P(a_1)P(b_1 | a_1) = \frac{1}{3} \end{array} \right.$$

$$P(a_i, b_j) = P(a_i)P(b_j \mid a_i) = P(b_j)P(a_i \mid b_j)$$

$$P(a_i) = \sum_k P(a_i, b_k) = \sum_k P(b_k)P(a_i \mid b_k)$$

$$P(b_j \mid a_i) = \frac{P(b_j)P(a_i \mid b_j)}{P(a_i)} = \frac{P(b_j)P(a_i \mid b_j)}{\sum_k P(a_i, b_k)} = \frac{P(b_j)P(a_i \mid b_j)}{\sum_k P(b_k)P(a_i \mid b_k)}$$



Thomas Bayes (1702-1761) a fost un pastor prezbiterian, disident al Bisericii Anglicane, educat la Universitatea din Scoția. Aici a studiat și matematica, pe care a continuat să o folosească în cercuri de discuții pe care le-a organizat, după ce a revenit în Anglia.

Formula, (relația lui Bayes) care l-a făcut celebru, s-a născut dintr-o dispută teologică. Este vorba de **influențele observațiilor (asupra particularului – accidentalului) vizavi de cunoașterea universalului.**

$$P(h_i | o) = P(h_i) \frac{P(o | h_i)}{P(o)}$$

Reverendul Bayes susținea faptul că observațiile ne transformă cunoașterea și a propus o formulă care a exprimă acest fenomen

După ce observația  $o$  s-a produs distribuția inițială se modifică astfel:

$$P(h_i | o) = P(h_i) \frac{P(o | h_i)}{P(o)}$$

*Ec 3-11*

unde:  $P(h_i | o)$  este denumită probabilitatea posteriori (după observație);

$P(h_i)$  este denumită probabilitatea priori (înainte de observație);

$P(o | h_i)$  este denumită likelihood, termen pe care l-am tradus prin adecvare.

scrie

| După aruncare          | $h_1$ : banul este corect | $h_2$ : banul este fals |
|------------------------|---------------------------|-------------------------|
| $o_1$ : a apărut stema | $P(o_1   h_1) = .5$       | $P(o_1   h_2) = .75$    |
| $o_2$ : a apărut banul | $P(o_2   h_1) = .5$       | $P(o_2   h_2) = .25$    |

Se face următoarea succesiune de experimente:

- Din sac se extrage o monedă;

$$P(h_1) = P(h_2) = .5$$

- Se aruncă, iar rezultatul este stema;

$$P(h_1 | o_1) \propto P(h_1)P(o_1 | h_1) = .5 \cdot .5 = .25$$

$$P(h_2 | o_1) \propto P(h_2)P(o_1 | h_2) = .5 \cdot .75 = .375$$

$$P(h_1 | o_1) = \frac{.25}{.25 + .375} = .4$$

$$P(h_2 | o_1) = \frac{.375}{.25 + .375} = .6$$

- Se aruncă iar (aceeași monedă) iar rezultatul e stema.

$$P(h_1 | o_1) \propto P(h_1)P(o_1 | h_1) = .4 \cdot .5 = .2$$

$$P(h_2 | o_1) \propto P(h_2)P(o_1 | h_2) = .6 \cdot .75 = .45$$

$$P(h_1 | o_1) = \frac{.2}{.2 + .45} = .308$$


$$P(h_2 | o_1) = \frac{.45}{.2 + .45} = .692$$

De remarcat faptul că după ambele observații care au fost favorabile ipotezei  $h_2$ , ipoteza  $h_1$  rămâne totuși utilizabilă.

În plus, tabelul 3-1 arată faptul că gradul de adecvare este sinonim cu conceptul de model.

### Exemplu

Pentru un eșantion reprezentativ format din 10 studenți se construiește modelul corelației dintre evenimentul reușita la examenul de *Algebră Liniară*, simbolizat cu A, și cea la examenul de *Teoria Sistemelor*, simbolizată cu B. Ambele variabile probabilistice au câte două valori posibile:  $a_1, b_1$  însemnând succesul, respectiv  $a_2, b_2$  eșecul. Rețeaua probabilistică este cea din figura 3-11.



A, B sunt cele două evenimente, în casetă este modelul corelației, calculat cu datele statistice înscrise în tabelul de mai jos.

Figura 3-11 Evenimentele A și B sunt corelate

Tabelul 3-2. Corelarea statistică între A și B

| Student         | Rezultatul la A | Rezultatul la B |
|-----------------|-----------------|-----------------|
| S <sub>1</sub>  | a <sub>1</sub>  | b <sub>1</sub>  |
| S <sub>2</sub>  | a <sub>1</sub>  | b <sub>1</sub>  |
| S <sub>3</sub>  | a <sub>1</sub>  | b <sub>1</sub>  |
| S <sub>4</sub>  | a <sub>1</sub>  | b <sub>1</sub>  |
| S <sub>5</sub>  | a <sub>1</sub>  | b <sub>2</sub>  |
| S <sub>6</sub>  | a <sub>1</sub>  | b <sub>2</sub>  |
| S <sub>7</sub>  | a <sub>2</sub>  | b <sub>2</sub>  |
| S <sub>8</sub>  | a <sub>2</sub>  | b <sub>2</sub>  |
| S <sub>9</sub>  | a <sub>2</sub>  | b <sub>2</sub>  |
| S <sub>10</sub> | a <sub>2</sub>  | b <sub>1</sub>  |

Tabelul este o colecție de observații referitoare la performanțele a 10 studenți  $S_{1,...,10}$  vizavi de examenele A și B. Simbolurile  $(a,b)_1$  precizează reușita iar  $(a,b)_2$  eșecul. Observațiile vor fi utilizate în calculul modelului din casetele care apar în figura 3-11.

$$\begin{cases} P(a_1) = \frac{6}{10} = \frac{3}{5} \\ P(a_2) = 1 - \frac{6}{10} = \frac{2}{5} \end{cases} \quad \begin{cases} P(b_1) = \frac{5}{10} = \frac{1}{2} \\ P(b_2) = \frac{1}{2} \end{cases}$$

$$\begin{cases} P(b_1 | a_1) = \frac{4}{6} \\ P(b_2 | a_1) = 1 - P(b_1 | a_1) = \frac{2}{6} \end{cases} \quad \begin{cases} P(b_1 | a_2) = \frac{1}{4} \\ P(b_2 | a_2) = 1 - P(b_1 | a_2) = \frac{3}{4} \end{cases}$$

$$\begin{cases} P(a_1 | b_1) = \frac{4}{5} \\ P(a_2 | b_1) = 1 - P(a_1 | b_1) = \frac{1}{5} \end{cases} \quad \begin{cases} P(a_1 | b_2) = \frac{2}{5} \\ P(a_2 | b_2) = 1 - P(a_1 | b_2) = \frac{3}{5} \end{cases}$$

Corelația A B poate fi considerată o legătură cauzală ceea ce ne permite propunerea unui formalism matriceal:

$$P(B)=_A^B \mathbf{P} \cdot P(A) \Leftrightarrow \begin{bmatrix} P(b_1) \\ P(b_2) \end{bmatrix} = \begin{bmatrix} P(b_1 | a_1) & P(b_1 | a_2) \\ P(b_2 | a_1) & P(b_2 | a_2) \end{bmatrix} \begin{bmatrix} P(a_1) \\ P(a_2) \end{bmatrix}$$

$$\begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \end{bmatrix} = \begin{bmatrix} \frac{4}{6} & \frac{1}{4} \\ \frac{2}{6} & \frac{3}{4} \end{bmatrix} \begin{bmatrix} \frac{3}{5} \\ \frac{2}{5} \end{bmatrix}$$

$$P(A)=_B^A \mathbf{P} \cdot P(B) \Leftrightarrow \begin{bmatrix} P(a_1) \\ P(a_2) \end{bmatrix} = \begin{bmatrix} P(a_1 | b_1) & P(a_1 | b_2) \\ P(a_2 | b_1) & P(a_2 | b_2) \end{bmatrix} \begin{bmatrix} P(b_1) \\ P(b_2) \end{bmatrix}$$

$$\begin{bmatrix} \frac{3}{5} \\ \frac{2}{5} \end{bmatrix} = \begin{bmatrix} \frac{4}{5} & \frac{2}{5} \\ \frac{1}{5} & \frac{3}{5} \end{bmatrix} \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \end{bmatrix}$$

Generalizând

$$P(b_j) = \sum_i P(b_j, a_i) = \sum_i P(a_i) P(b_j | a_i)$$

$$= \begin{bmatrix} P(b_j | a_1) & \dots & P(b_j | a_n) \end{bmatrix} \cdot \begin{bmatrix} P(a_1) \\ \dots \\ P(a_n) \end{bmatrix} \Rightarrow$$

Modelul direct  
A->B

$$P(B) = \begin{bmatrix} P(b_1 | a_1) & \dots & P(b_1 | a_n) \\ \vdots & \dots & \vdots \\ P(b_m | a_1) & \dots & P(b_m | a_n) \end{bmatrix} \begin{bmatrix} P(a_1) \\ \dots \\ P(a_n) \end{bmatrix} \Leftrightarrow$$

$$P(B)=_A^B \mathbf{P} \cdot P(A)$$




Figura 3-12. Diagrama cauzală: A este cauza B este efectul

Pentru sistemul din figura 3-12 ne interesează inversarea modelului, adică efectul observației valorii  $b_j$  asupra distribuției de probabilitate  $P(A)$ . Mai precis: a apărut  $b_1$  sau  $b_2$  și ne interesează distribuția de probabilitate  $P(A)$ . Vom utiliza în acest sens relația lui Bayes:

$$P(A | b_j) = P(A) \frac{P(b_j | A)}{p(b_j)}$$

Modelul invers  
 $A \rightarrow b_j \rightarrow A$

sau într-o formă matriceală

$$P(A | b_j) = \frac{{}^{b_j}_A \mathbf{P}^T \otimes P(A)}{{}^{b_j}_A \mathbf{P} \cdot P(A)}$$

$$\text{unde: } P(A | b_j) = \begin{bmatrix} P(a_1 | b_j) \\ \dots \\ P(a_n | b_j) \end{bmatrix};$$


$${}^{b_j}_A \mathbf{P} = \begin{bmatrix} P(b_j | a_1) & \dots & P(b_j | a_n) \end{bmatrix} = {}^B_A \mathbf{P}(\mathbf{j}, :)$$

${}^B_A \mathbf{P}(\mathbf{j}, :)$  este rândul  $j$  din matricea  ${}^B_A \mathbf{P}$

$$P(A) = \begin{bmatrix} P(a_1) \\ \dots \\ P(a_n) \end{bmatrix}$$

$\otimes$  este un produs de tipul, element cu element

$$\begin{bmatrix} P(b_j | a_1) & \dots & P(b_j | a_n) \end{bmatrix}^T \otimes \begin{bmatrix} P(a_1) \\ \dots \\ P(a_n) \end{bmatrix} = \begin{bmatrix} P(a_1)P(b_j | a_1) \\ \dots \\ P(a_n)P(b_j | a_n) \end{bmatrix}$$




Filtrul Bayesian

1. Introducere

2. Formalism


3. Simulări

4. Concluzii



Pentru modelarea și simularea procesului descris, putem utiliza diagrama cauzală din figura 3-34.

Modelarea procesului presupune utilizarea modelului direct pentru colimator (**V**) și a celui invers pentru lanț (**I**). Relațiile utilizate sunt cele din tabelul 3-8.




$$P(X_{i+1}) = \begin{smallmatrix} X_{i+1} \\ X_i U_{i+1} \end{smallmatrix} P P(X_i) P(U_{i+1})$$

Ec 3-55

$$P(X_{i+1} | z_k) = \frac{\begin{smallmatrix} z_k \\ X_{i+1} \end{smallmatrix} P^T \otimes P(X_{i+1})}{\begin{smallmatrix} z_k \\ X_{i+1} \end{smallmatrix} P \cdot P(X_{i+1})}$$


Ec 3-56


Figura 3-34. Diagrama cauzală a procesului



$$p(x_{i+1} | x_i) = 0.8$$

$$p(x_{i+2} | x_i) = 0.2$$






$$p(x_{i+1} \mid x_i) = 0.8$$


$$p(x_{i+2} \mid x_i) = 0.2$$

| 1          | 2                      | 3                        | 4                        | 5                        | 6                        | 7        | 8        |
|------------|------------------------|--------------------------|--------------------------|--------------------------|--------------------------|----------|----------|
| <b>0.9</b> | <b>0.1</b>             | <b>0</b>                 | <b>0</b>                 | <b>0</b>                 | <b>0</b>                 | <b>0</b> | <b>0</b> |
|            | $0.9 \cdot 0.8 = 0.72$ | $0.9 \cdot 0.2 = 0.18$   |                          |                          |                          |          |          |
|            |                        | $0.1 \cdot 0.8 = 0.08$   | $0.1 \cdot 0.2 = 0.02$   |                          |                          |          |          |
| <b>0</b>   | <b>0.72</b>            | <b>0.26</b>              | <b>0.02</b>              | <b>0</b>                 | <b>0</b>                 | <b>0</b> | <b>0</b> |
|            |                        | $0.72 \cdot 0.8 = 0.576$ | $0.72 \cdot 0.2 = 0.144$ |                          |                          |          |          |
|            |                        |                          | $0.26 \cdot 0.8 = 0.208$ | $0.26 \cdot 0.2 = 0.052$ |                          |          |          |
|            |                        |                          |                          | $0.02 \cdot 0.8 = 0.016$ | $0.02 \cdot 0.2 = 0.004$ |          |          |
| <b>0</b>   | <b>0</b>               | <b>0.576</b>             | <b>0.352</b>             | <b>0.068</b>             | <b>0.004</b>             | <b>0</b> | <b>0</b> |



***Probabilitatea maximă a distribuțiilor are o tendință descrescătoare. Mai precis: cunoaștem din ce în ce mai puțin atunci când rulăm succesiv modelul.***  
 La limită, distribuția de probabilitate se va transforma într-una uniformă, fiecare stare va avea aceeași probabilitate.

Pentru a contracara acest inconvenient este necesară o etapă de **corecție** al cărei rol este de a media rezultatele **predicției** cu cele ale **observației**.



$$p(z_i | x_i = z_i) = 0.9$$

$$p(z_i | x_i \neq z_i) = 0.1$$

$$bel(x_1^j | z) = \eta \cdot bel(x_1^j) \cdot p(z | x_1^j)$$



$$bel(x_i^j | z)$$

este probabilitatea a posteriorii a stării  $x_i^j$  de la pasul 1 atunci când există observația  $z$ ;

$$bel(x_1^j)$$

este probabilitatea a priorii a stării  $x^j$ ;


$$p(z | x_1^j)$$

este probabilitatea de concordanță dintre starea  $x^j$  și observația  $z$  (the likelihood);

$$\eta$$

este un coeficient de normare pe toată distribuția  $j$ ;

| 1   | 2                       | 3                        | 4                        | 5 | 6 | 7 | 8 |
|-----|-------------------------|--------------------------|--------------------------|---|---|---|---|
|     |                         |                          |                          |   |   |   |   |
| 0.9 | 0.1                     | 0                        | 0                        | 0 | 0 | 0 | 0 |
|     | $0.9 \cdot 0.8 = 0.72$  | $0.9 \cdot 0.2 = 0.18$   |                          |   |   |   |   |
|     |                         | $0.1 \cdot 0.8 = 0.08$   | $0.1 \cdot 0.2 = 0.02$   |   |   |   |   |
| 0   | 0.72                    | 0.26                     | 0.02                     | 0 | 0 | 0 | 0 |
|     | $0.72 \cdot 0.9 = 0.64$ | $0.26 \cdot 0.1 = 0.026$ | $0.02 \cdot 0.9 = 0.018$ |   |   |   |   |
|     | Sum=0.684               |                          |                          |   |   |   |   |
|     | 0.936                   | 0.038                    | 0.026                    |   |   |   |   |



Ceea ce este important de observat este faptul că: ***probabilitatea maximă a distribuției, după observații, este mai mare decât cea precedentă.***

***Mai precis: cunoaștem din ce în ce mai mult cu ajutorul observațiilor.***


**Predicția:** utilizează distribuțiile de probabilitate ale modelului și ale stării inițiale. Rezultatul este o distribuție de probabilitate a stării consecutive denumite apriori sau estimată

$${}^{\Lambda}bel(x_i) = \int p(x_i | u_i, x_{i-1}) \cdot bel(x_{i-1}) d(x_{i-1})$$


**Corecția:** mediază rezultatul observației cu cel estimat

$$bel(x_i) = \eta \cdot p(z_i | x_i) \cdot {}^{\Lambda}bel(x_i)$$

$$bel^{\Lambda}(x_i) = \int p(x_i | u_i, x_{i-1}) \cdot bel(x_{i-1}) d(x_{i-1})$$



$$bel^{\Lambda}(x_i) = \eta \cdot p(z_i | x_i) \cdot bel(x_i)$$



*Simulari*


# Cazul 1D, RM se deplasează pe o traiectorie circulară

Modelul locomoției și al senzorilor

$$\begin{cases} p(x_i^{j+1} | x_{i-1}^j, u_i) = 0.1 \\ p(x_i^{j+2} | x_{i-1}^j, u_i) = 0.7; \\ p(x_i^{j+3} | x_{i-1}^j, u_i) = 0.2 \end{cases}; \begin{cases} p(z^j | x^j = z^j) = 0.9 \\ p(z^j | x^j \neq z^j) = 0.1 \end{cases}$$



Rezultatele simulării (3 pași) care nu conțin observații; probabilitatea maximă scade pas cu pas.




Rezultatele simulării, (3 pași), care conțin observații, probabilitatea maximă crește pas cu pas

# Cazul 2D, RM se deplasează pe o traiectorie așezată pe o sferă

Modelul locomoției și al senzorilor


Pe axa x: 
$$\begin{cases} p(x_i^{j+1} | x_{i-1}^j, u_i) = 0.1 \\ p(x_i^{j+2} | x_{i-1}^j, u_i) = 0.7 \\ p(x_i^{j+3} | x_{i-1}^j, u_i) = 0.2 \end{cases}$$




Pe axa y: 
$$\begin{cases} p(x_i^{j+1} | x_{i-1}^j, u_i) = 0.1 \\ p(x_i^{j+2} | x_{i-1}^j, u_i) = 0.6 \\ p(x_i^{j+3} | x_{i-1}^j, u_i) = 0.2 \\ p(x_i^{j+4} | x_{i-1}^j, u_i) = 0.1 \end{cases}$$

Măsurători: 
$$\begin{cases} p(z^j | x^j = z^j) = 0.9 \\ p(z^j | x^j \neq z^j) = 0.1 \end{cases}$$


Starea inițială



## Rezultatele simulării care nu conține observații (4 pași)



## Rezultatele simulării care conține observații (4 pași)






Concluzii

Filtrul Bayesian este un estimator care utilizează un algoritm compus din două etape: predicția și corecția.

**Predicția** estimează vectorul de stare al modelului. Subliniem faptul că în afara ipotezei markoviene **nu au existat alte ipoteze referitoare la modelul utilizat**, el putând fi liniar sau neliniar. Modelul este afectat de perturbații, fapt care-i determină caracterul stocastic. Nici în acest caz **nu există ipoteze adiționale, distribuția de probabilitate poate fi oarecare.**

**Corecția** reprezintă o mediere între vectorul de stare estimat anterior și vectorul de stare măsurat. Subliniem faptul că, în general, cei doi vectori menționați se referă la mărimi diferite. **Nu putem măsura direct vectorul care ne interesează**, ci măsurăm un vector care poate fi corelat cu acesta. La rândul ei măsurătoarea este afectată de zgomot, modelul ei este unul stocastic dar care (nici în acest caz) **nu necesită o distribuție de probabilitate anume.**

| Denumirea filtrului           | Tipul modelului | Distribuția de probabilitate | Volumul de calcul necesar                                           |
|-------------------------------|-----------------|------------------------------|---------------------------------------------------------------------|
|                               | ipoteze         |                              |                                                                     |
| Filtrul Kalman                | Liniar          | Gaussiană                    | Mic                                                                 |
| Extended Kalman Filter (EKF)  | Local liniar    | Gaussiană                    | Mic, dacă dispunem de Jacobianul analitic;<br>Mediu, în caz contrar |
| Unscented Kalman Filter (UKF) | Neliniar        | Gaussiană                    | Mic - Mediu                                                         |
| Filtrul de Particule          | Neliniar        | Oarecare                     | Mare                                                                |



1. Introducere

2. Formalism

3. Simulări

4. Concluzii

Filtrul Kalman



Kálmán Rudolf Emil; născut la 19 mai 1930 este un inginer, matematician și inventator, american de origine maghiară. El este remarcat mai ales pentru co-invenția și dezvoltarea filtrului Kalman, un algoritm matematic care este utilizat pe scară largă în procesarea semnalului, sisteme de control și ghidare, navigare și control.


Important de menționat primele exemple de implementare ale filtrului, adică primele beneficii practice. Poate cel mai spectaculoasă este utilizarea lui în **programul spațial Apollo**, pentru estimarea traiectoriei rachetei, pe un calculator 36k cu o frecvență de 100kHz. Au urmat implementări în industria militară, la rachete balistice nucleare ale Marinei SUA, la sistemele de ghidare și de navigare a rachetelor de croazieră, precum racheta Tomahawk

Filtrul Kalman este **o particularizare** a filtrului Bayesian.

Utilizând **ipoteza modelului liniar** și cea **a distribuției de probabilitate Gaussiană**, îl transformă într-un formalism cu **volumului de calcul redus**.

Este filtrul cu cea mai mare notorietate, din familia prezentată în tabelul precedent.

| Denumirea filtrului           | Tipul modelului | Distribuția de probabilitate | Volumul de calcul necesar                                           |
|-------------------------------|-----------------|------------------------------|---------------------------------------------------------------------|
|                               | ipoteze         |                              |                                                                     |
| Filtrul Kalman                | Liniar          | Gaussiană                    | Mic                                                                 |
| Extended Kalman Filter (EKF)  | Local liniar    | Gaussiană                    | Mic, dacă dispunem de Jacobianul analitic;<br>Mediu, în caz contrar |
| Unscented Kalman Filter (UKF) | Neliniar        | Gaussiană                    | Mic - Mediu                                                         |
| Filtrul de Particule          | Neliniar        | Oarecare                     | Mare                                                                |



Dacă  $\hat{z}$  converge  
spre  $z$  atunci  $\hat{x}$   
converge spre  $x$

Ideea estimatorului este ca valoarea estimată să convergă către cea măsurată astfel încât, în final, vectorul de stare estimat să convergă către cel real

$$\mathbf{e} = \mathbf{x} - \hat{\mathbf{x}}$$

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u}$$

$$\dot{\hat{\mathbf{x}}} = \mathbf{A}\hat{\mathbf{x}} + \mathbf{B}\mathbf{u} + \mathbf{K}(\mathbf{y} - \hat{\mathbf{y}})$$

$$\dot{\mathbf{e}} = \dot{\mathbf{x}} - \dot{\hat{\mathbf{x}}} = (\mathbf{A} + \mathbf{K}\mathbf{C})\mathbf{e}$$


$$\begin{cases} \mathbf{x}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{B}\mathbf{u}_k + \mathbf{w}_k \\ \mathbf{z}_k = \mathbf{C}\mathbf{x}_k + \mathbf{v}_k \end{cases}$$

$$\mathbf{w}_k, \mathbf{v}_k$$

Sunt perturbațiile  
respectiv  
zgomotul la iterația  $k$ , acestea au distribuții normale

$$\mathbf{w} \approx N(0, \mathbf{Q}), \mathbf{v} \approx N(0, \mathbf{R})$$

$\mathbf{Q}$ ,  $\mathbf{R}$  sunt matricele  
de covarianță.




$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-(x-\mu)^2}{2\sigma^2}\right)$$

$\sigma$  este denumită deviația standard;

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$


$$P_{x1}^{x2} = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{x=x1}^{x=x2} \exp\left(\frac{-(x-\mu)^2}{2\sigma^2}\right) dx$$



Distribuția este asimilată în domeniul continuu cu densitatea de probabilitate, concept similar cu conceptul mecanic de sarcină distribuită. Prin integrare între anumite limite densitatea de probabilitate se transformă în probabilitatea din acel domeniu


$$P_{x1}^{x2} = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{x=x1}^{x=x2} \exp\left(\frac{-(x-\mu)^2}{2\sigma^2}\right) dx$$

- Transformările lineare ale densității de probabilitate Gaussiene devin **noi distribuții de densitate Gaussiene** (diferite prin valoarea medie și abaterea standard). Proprietatea va fi corelată cu **obținerea estimării apriori**, cea datorată modelului, care în acest caz este unul liniar:



$$y_i = ax_i + b$$
$$\Rightarrow \begin{cases} \mu_y = a\mu_x + b \\ \sigma_y = a\sigma_x \end{cases}$$

- Înmulțirea a două densități de probabilitate Gaussiene este **o nouă distribuție de probabilitate Gaussiană**. Proprietatea va fi corelată cu obținerea **estimării posteriori, în urma măsurărilor**, cu zgomot, definite tot printr-o distribuție Gaussiană



$$p(\mu, \sigma) = \eta \cdot p(\mu_1, \sigma_1) \cdot p(\mu_2, \sigma_2)$$

$$\Rightarrow \begin{cases} \mu = \frac{\left( \frac{1}{\sigma_1^2} \mu_1 + \frac{1}{\sigma_2^2} \mu_2 \right)}{\left( \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \right)} \\ \frac{1}{\sigma^2} = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \end{cases} \Leftrightarrow \begin{cases} \mu = \mu_1 + K(\mu_2 - \mu_1) \\ \sigma^2 = \sigma_1^2(1-K) \\ K = \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \end{cases}$$


$$K = \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \begin{cases} \sigma_1 \rightarrow \infty \Rightarrow K \rightarrow 1 \Rightarrow \begin{cases} \mu \rightarrow \mu_2 \\ \sigma \rightarrow 0 \end{cases} \\ \sigma_2 \rightarrow \infty \Rightarrow K \rightarrow 0 \Rightarrow \begin{cases} \mu \rightarrow \mu_1 \\ \sigma \rightarrow \sigma_1 \end{cases} \end{cases}$$

Modelul RM:  $x_k = 2x_{k-1} + 2$ . Exemplul cuprinde două etape: cea de predicție care utilizează modelul și cea de corecție care integrează măsurătoarea  $z$  și zgomotul acesteia în rezultatul final.

Starea inițială a RM:

$$\mu_0 = 0$$

$$\sigma_0 = 1.5$$




După primul pas:

$$x_1 = 2x_0 + 2$$

$$\mu_p = 2$$


$$\sigma_p = 3$$



Observația:

$$z = 5$$

$$\sigma = 1.2$$






Corecția, rezultatul  
final

$$\mu_c = 3,9$$

$$\sigma_c = 1.05$$

(v. eq 5.21)





$$p(\mathbf{x}) = \frac{1}{\sqrt{2\pi}} |\boldsymbol{\Sigma}|^{-\frac{1}{2}} \exp\left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})\right)$$

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$$

$$\sigma_{1,2}^2 = \frac{1}{N} \sum_{i=1}^N (x_{1,2}^i - \mu_{1,2})^2$$

$$\rho = \frac{1}{N} \frac{\sum_{i=1}^N (x_1^i - \mu_1)(x_2^i - \mu_2)}{\sigma_1\sigma_2}$$

$$\boldsymbol{\mu} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$$

**Predicția:** utilizează distribuțiile de probabilitate ale modelului și ale stării inițiale. Rezultatul este o distribuție de probabilitate a stării consecutive denumite apriori sau estimată

$$\hat{\mathbf{x}}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{B}\mathbf{u}_k$$
$$\hat{\Sigma}_k = \mathbf{A}\Sigma_{k-1}\mathbf{A}^T + \mathbf{Q}$$

**Corecția:** mediază rezultatul observației cu cel estimat

$$\mathbf{K}_k = \frac{\hat{\Sigma}_k \mathbf{C}^T}{\mathbf{C}\hat{\Sigma}_k \mathbf{C}^T + \mathbf{R}}$$
$$\mathbf{x}_k = \hat{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{z}_k - \mathbf{C}\hat{\mathbf{x}}_k)$$
$$\Sigma_k = (\mathbf{I} - \mathbf{K}_k \mathbf{C}) \hat{\Sigma}_k$$

$$\hat{\mathbf{x}}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{B}\mathbf{u}_k$$

$$\hat{\Sigma}_k = \mathbf{A}\Sigma_{k-1}\mathbf{A}^T + \mathbf{Q}$$


unde:  $\hat{\mathbf{x}}_k$  este starea estimată la iterația  $k$  (simbolul  $\wedge$  se referă la statutul de estimat);  $\mathbf{x}_{k-1}, \mathbf{u}_k$  sunt vectorii de stare și cel de comandă la iterația  $k-1$ , respective  $k$ , /  $\hat{\Sigma}_k$  este matricea de covarianță estimată la iterația  $k$   $\Sigma_{k-1}, \mathbf{Q}$  sunt matricele de covarianță de la pasul  $k-1$  respectiv varianța mărimii de comandă.


$$\mathbf{K}_k = \frac{\hat{\Sigma}_k \mathbf{C}^T}{\mathbf{C} \hat{\Sigma}_k \mathbf{C}^T + \mathbf{R}}$$

$$\mathbf{x}_k = \hat{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{z}_k - \mathbf{C} \hat{\mathbf{x}}_k)$$

$$\Sigma_k = (\mathbf{I} - \mathbf{K}_k \mathbf{C}) \hat{\Sigma}_k$$

unde:  $\mathbf{K}_k$  este coeficientul lui Kalman la iterația  $k$ ,  $\mathbf{R}$  este covarianța zgomotului de măsurare (v. Eq.5.21); matricea de ieșire,  $\mathbf{C}$ , are rolul de adaptare dimensională;  $\hat{\mathbf{x}}_k$  este starea estimată la iterația  $k$   $\mathbf{z}_k$  este mărimea măsurată la pasul  $k$ ;  $(\mathbf{z}_k - \mathbf{C} \hat{\mathbf{x}}_k)$  este inovația;  $\Sigma_k$  este matricea de covarianță calculate la iterația  $k$ .





*Símulari*

$$x = x_0 + \dot{x}_0 t + 0.5at^2 \quad \begin{cases} \dot{x}(k+1) = \dot{x}(k) + a\Delta t \\ x(k+1) = x(k) + \dot{x}(k)\Delta t + 0.5a\Delta t^2 \end{cases} \quad \begin{bmatrix} x(k+1) \\ \dot{x}(k+1) \end{bmatrix} = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x(k) \\ \dot{x}(k) \end{bmatrix} + \begin{bmatrix} 0.5\Delta t^2 \\ \Delta t \end{bmatrix} a$$

$$\mathbf{x}(k+1) = \mathbf{F}\mathbf{x}(k) + \mathbf{G}u(k)$$

$$\mathbf{z}(k+1) = \mathbf{H}\mathbf{x}(k)$$

$$\begin{cases} \mathbf{F} = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \\ \mathbf{G} = \begin{bmatrix} 0.5\Delta t^2 \\ \Delta t \end{bmatrix} \\ u(k) = a \\ \mathbf{H} = [1 \quad 0] \end{cases}$$

$$\mathbf{x}(k+1) = \mathbf{F}\mathbf{x}(k) + \mathbf{G}u(k) + \mathbf{w}(k)$$

$$\mathbf{z}(k+1) = \mathbf{H}\mathbf{x}(k) + \mathbf{v}(k)$$

$$\Sigma_0 = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$$

$$\mathbf{w}(k) \approx N(0, \mathbf{Q})$$

$$\mathbf{v}(k) \approx N(0, R)$$

$$\mathbf{Q} = \mathbf{G}\mathbf{G}^T \sigma_a^2$$

$$R = \sigma_v^2$$

# PREDICTIA

$$\hat{\mathbf{x}}(k+1) = \mathbf{F}\mathbf{x}(k) + \mathbf{G}u(k)$$

$$\hat{\Sigma}_w(k+1) = \mathbf{F}\Sigma_w(k)\mathbf{F}^T + \mathbf{Q}$$

$$\begin{aligned} \begin{bmatrix} x(k+1) \\ \dot{x}(k+1) \end{bmatrix} &= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x(k) \\ \dot{x}(k) \end{bmatrix} + \begin{bmatrix} 0.5\Delta t^2 \\ \Delta t \end{bmatrix} a \\ \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}_{k+1} &= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}_k \begin{bmatrix} 1 & 0 \\ \Delta t & 1 \end{bmatrix} + \begin{bmatrix} 0.5\Delta t^2 \\ \Delta t \end{bmatrix} \begin{bmatrix} 0.5\Delta t^2 & \Delta t \end{bmatrix} \sigma_a^2 \\ \begin{bmatrix} x(k+1) \\ \dot{x}(k+1) \end{bmatrix} &= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x(k) \\ \dot{x}(k) \end{bmatrix} + \begin{bmatrix} 0.5\Delta t^2 \\ \Delta t \end{bmatrix} a \\ \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}_{k+1} &= \begin{bmatrix} (\sigma_{11} + \sigma_{12}\Delta t)^2 & (\sigma_{11} + \sigma_{12}\Delta t)\sigma_{22} \\ (\sigma_{11} + \sigma_{21}\Delta t)\sigma_{22} & \sigma_{22}^2 \end{bmatrix} + \begin{bmatrix} 0.25\Delta t^4 & 0.5\Delta t^3 \\ 0.5\Delta t^3 & \Delta t^2 \end{bmatrix} \sigma_a^2 \end{aligned}$$

$$\mathbf{x}(k+1) = \hat{\mathbf{x}}(k+1) + \mathbf{K}(k+1)\mathcal{G}(k+1)$$

$$\begin{bmatrix} x(k+1) \\ \dot{x}(k+1) \end{bmatrix} = \begin{bmatrix} \hat{x}(k+1) \\ \hat{\dot{x}}(k+1) \end{bmatrix} + \begin{bmatrix} \frac{\sigma_{11}^2}{(\sigma_{11}^2 + \sigma_v^2)} \\ \frac{\sigma_{p12}}{(\sigma_{11}^2 + \sigma_v^2)} \end{bmatrix} (z(k+1) - \hat{x}(k+1))$$


$$\Sigma(k+1) = \hat{\Sigma}(k+1) - \mathbf{K}(k+1)\mathbf{H}\hat{\Sigma}(k+1)$$

$$\begin{aligned} \Sigma(k+1) &= \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}_{k+1} - \begin{bmatrix} \frac{\sigma_{11}^2}{(\sigma_{11}^2 + \sigma_v^2)} \\ \frac{\sigma_{p12}}{(\sigma_{11}^2 + \sigma_v^2)} \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}_{k+1} = \\ &= \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}_{k+1} - \begin{bmatrix} \frac{\sigma_{11}^2}{(\sigma_{11}^2 + \sigma_v^2)} \sigma_{11}^2 & \frac{\sigma_{11}^2}{(\sigma_{11}^2 + \sigma_v^2)} \sigma_{12} \\ \frac{\sigma_{12}}{(\sigma_{11}^2 + \sigma_v^2)} \sigma_{11}^2 & \frac{\sigma_{12}}{(\sigma_{11}^2 + \sigma_v^2)} \sigma_{12} \end{bmatrix} \end{aligned}$$


$$\begin{aligned} \mathbf{K}(k+1) &= \hat{\Sigma}(k+1)\mathbf{H}^T \left( \mathbf{H}\hat{\Sigma}(k+1)\mathbf{H}^T + R \right)^{-1} \\ \mathbf{K}(k+1) &= \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{p22}^2 \end{bmatrix}_{k+1} \begin{bmatrix} 1 \\ 0 \end{bmatrix} \left( \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}_{k+1} \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \sigma_v^2 \right)^{-1} \\ \mathbf{K}(k+1) &= \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}_{k+1} \begin{bmatrix} 1 \\ 0 \end{bmatrix} (\sigma_{11}^2 + \sigma_w^2)^{-1} = \begin{bmatrix} \frac{\sigma_{11}^2}{(\sigma_{11}^2 + \sigma_w^2)} \\ \frac{\sigma_{12}}{(\sigma_{11}^2 + \sigma_w^2)} \end{bmatrix} \\ \mathcal{G}(k+1) &= \mathbf{z}(k+1) - \mathbf{H}\hat{\mathbf{x}}(k+1) \end{aligned}$$



$$\mathcal{G}(k+1) = \mathbf{z}(k+1) - \mathbf{H}\hat{\mathbf{x}}(k+1) = z(k+1) - \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} \hat{x}(k+1) \\ \hat{\dot{x}}(k+1) \end{bmatrix} = z(k+1) - \hat{x}(k+1)$$

$\Sigma_0 = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix}; \sigma_v = 0.05; \sigma_a = 0.05$ ; Nu s-a utilizat filtrul Kalman, amprenta eliptică crește, corelația dintre stări crește; x1 poziția, x2 viteza.



$\Sigma_0 = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix}; \quad \sigma_v = 0.05; \quad \sigma_a = 0.05$ ; S-a utilizat filtrul Kalman, amprenta eliptică scade corelația dintre stări crește; x1 poziția, x2 viteza.








Concluzii

Filtrul Kalman este o particularizare a filtrului Bayesian, posibilă prin asumarea a **două ipoteze: modelul sistemului este liniar și distribuția de probabilitate a perturbației și a zgomotului este Gaussiană.**

Formalismul construit pe acest fundament conceptual utilizează reprezentarea din spațiul stărilor. Principalul beneficiu vizavi de varianta Bayesiană este reducerea volumului computațional, **deoarece distribuția de probabilitate este parametrică ( $\mu, \sigma$ ).**

La fel ca filtrul Bayesian, filtrul Kalman asigură creștere acurateței rezultatelor și posibilitatea estimării unor componente care nu au putut fi măsurate direct.



1. Introducere

2. Formalism

3. Simulări


4. Concluzii

Filtrul Kalman Extins (EKF)

În cele mai multe cazuri, inclusiv cel al RM, **ipoteza modelului liniar este inacceptabilă.**

Pentru a beneficia și în aceste situații, de avantajele filtrului Kalman se acceptă (uneori) un compromis, care constă în **liniarizarea modelului în jurul stării curente.**

Apare astfel un nou formalism denumit Filtrul Kalman Extins (EKF).



Senzor:  
Model neliniar + zgomot Gaussian

Soluția 1

Filtrul Kalman:  
Model liniarizat  
în  $\mathbf{x}=0$

Soluția 2

Filtrul EKF:  
Model liniarizat  
în  $\mathbf{x}_k$

$$\ddot{q} + \frac{g}{l}q = 0 \Leftrightarrow \begin{cases} x_1 = q \\ x_2 = \dot{q} \end{cases} \Leftrightarrow \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -\frac{g}{l} & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$z = x_1 = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\mathbf{F} = \begin{bmatrix} 0 & 1 \\ -\frac{g}{l} & 0 \end{bmatrix} \quad \mathbf{H} = \begin{bmatrix} 1 & 0 \end{bmatrix} \quad \mathbf{G} = 0$$

$$\begin{cases} Q \\ R = \sigma_v \end{cases}$$

$$\Sigma_0 = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$$

$$\ddot{q} + \frac{g}{l}q = 0 \Leftrightarrow \begin{cases} x_1 = q \\ x_2 = \dot{q} \end{cases} \Leftrightarrow \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} = \begin{bmatrix} x_2 \\ -\frac{g}{l} \sin x_1 \end{bmatrix}$$



$$\begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} = \begin{bmatrix} x_2 \\ -\frac{g}{l} \sin x_1 \end{bmatrix}_{\mathbf{x}_k} + \begin{bmatrix} \frac{\partial x_2}{\partial x_1} & \frac{\partial x_2}{\partial x_2} \\ \frac{\partial \left(-\frac{g}{l} \sin x_1\right)}{\partial x_1} & \frac{\partial \left(-\frac{g}{l} \sin x_1\right)}{\partial x_2} \end{bmatrix}_{\mathbf{x}_k} (\mathbf{x} - \mathbf{x}_k)$$

$$\mathbf{F} = \begin{bmatrix} \frac{\partial x_2}{\partial x_1} & \frac{\partial x_2}{\partial x_2} \\ \frac{\partial \left(-\frac{g}{l} \sin x_1\right)}{\partial x_1} & \frac{\partial \left(-\frac{g}{l} \sin x_1\right)}{\partial x_2} \end{bmatrix}_{\mathbf{x}_k} = \begin{bmatrix} 0 & 1 \\ -\frac{g}{l} \cos x_1 & 0 \end{bmatrix} \quad \mathbf{H} = \begin{bmatrix} 1 & 0 \end{bmatrix} \quad \mathbf{G} = 0$$



## Soluția Filtrului Kalman

## Soluția Filtrului Kalman Extins



Pentru valori mici ale unghiului de poziție ambele soluții se comportă bine, zgomotul este eliminat





## Detalii



Pentru valori mari ale unghiului de poziție inițial soluții se comportă în mod diferit, zgomotul este eliminat dar valorile estimate ale soluției 1 sunt divergente vizavi de cele reale.




## Detalii



$$\begin{cases} \dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}, \mathbf{u}) \\ \mathbf{y} = \mathbf{h}(\mathbf{x}) \end{cases}$$

$$\dot{\mathbf{x}} \cong \mathbf{f}(\mathbf{x}_k, \mathbf{u}_k) + \frac{\partial \mathbf{f}(\mathbf{x}, \mathbf{u})}{\partial \mathbf{x}} \bigg|_{\substack{\mathbf{x}=\mathbf{x}_k \\ \mathbf{u}=\mathbf{u}_k}} (\mathbf{x} - \mathbf{x}_k) + \frac{\partial \mathbf{f}(\mathbf{x}, \mathbf{u})}{\partial \mathbf{u}} \bigg|_{\substack{\mathbf{x}=\mathbf{x}_k \\ \mathbf{u}=\mathbf{u}_k}} (\mathbf{u} - \mathbf{u}_k)$$

$$\mathbf{y} \cong \mathbf{h}(\mathbf{x}_k) + \frac{\partial \mathbf{h}(\mathbf{x})}{\partial \mathbf{x}} \bigg|_{\mathbf{x}=\mathbf{x}_k} (\mathbf{x} - \mathbf{x}_k)$$



$$\begin{cases} \mathbf{F} = \frac{\partial \mathbf{f}(\mathbf{x}_0, \mathbf{u}_0)}{\partial \mathbf{x}}; \mathbf{G} = \frac{\partial \mathbf{f}(\mathbf{x}_0, \mathbf{u}_0)}{\partial \mathbf{u}} \\ \mathbf{H} = \frac{\partial \mathbf{h}(\mathbf{x}_0)}{\partial \mathbf{x}} \end{cases}$$

$$\frac{\partial \mathbf{f}(\mathbf{x}_k, \mathbf{u}_k)}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \dots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}_{\mathbf{x}_k, \mathbf{u}_k}$$

$$\frac{\partial \mathbf{f}(\mathbf{x}_k, \mathbf{u}_k)}{\partial \mathbf{u}} = \begin{bmatrix} \frac{\partial f_1}{\partial u_1} & \dots & \frac{\partial f_1}{\partial u_m} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial u_1} & \dots & \frac{\partial f_n}{\partial u_m} \end{bmatrix}_{\mathbf{x}_k, \mathbf{u}_k}$$

$$\frac{\partial \mathbf{h}(\mathbf{x}_k)}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial h}{\partial x_1} & \dots & \frac{\partial h}{\partial x_n} \end{bmatrix}_{\mathbf{x}_k}$$

**Predicția:** utilizează distribuțiile de probabilitate ale modelului și ale stării inițiale. Rezultatul este o distribuție de probabilitate a stării consecutive denumite apriori sau estimată

$$\hat{\mathbf{x}}_k = \mathbf{f}^*(\mathbf{x}_{k-1}, \mathbf{u}_k)$$

$$\hat{\Sigma}_k = \mathbf{F}\Sigma_{k-1}\mathbf{F}^T + \mathbf{G}\Sigma_C\mathbf{G}^T$$

**Corecția:** mediază rezultatul observației cu cel estimat

$$\mathbf{K}_k = \frac{\hat{\Sigma}_k \mathbf{H}^T}{\mathbf{H}\hat{\Sigma}_k \mathbf{H}^T + \mathbf{R}}$$

$$\mathbf{x}_k = \hat{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}\hat{\mathbf{x}}_k)$$

$$\Sigma_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}) \hat{\Sigma}_k$$

$$\hat{\mathbf{x}}_k = \mathbf{f}^*(\mathbf{x}_{k-1}, \mathbf{u}_k)$$

$$\hat{\Sigma}_k = \mathbf{F}\Sigma_{k-1}\mathbf{F}^T + \mathbf{G}\Sigma_c\mathbf{G}^T$$


unde:  $\mathbf{f}^*$  este o soluție numerică a ecuației diferențiale 5.31  $\hat{\mathbf{x}}_k$  este starea estimată la iterația  $k$  (simbolul  $\hat{\phantom{x}}$  se referă la statutul de estimat);  $\mathbf{x}_{k-1}, \mathbf{u}_k$  sunt vectorii de stare și cel de comandă la iterația  $k-1$ , respective  $k$ ;  $\mathbf{F}$  este Jacobianul funcției  $\mathbf{f}$ ,  $\hat{\Sigma}_k$  este matricea de covarianță estimată la iterația  $k$ ,  $\Sigma_{k-1}$  sunt matricele de covarianță de la pasul  $k-1$ , respectiv  $\mathbf{Q} = \mathbf{G}\Sigma_c\mathbf{G}^T$  este varianța mărimii de comandă.


$$\mathbf{K}_k = \frac{\hat{\Sigma}_k \mathbf{H}^T}{\mathbf{H} \hat{\Sigma}_k \mathbf{H}^T + \mathbf{R}}$$

$$\mathbf{x}_k = \hat{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H} \hat{\mathbf{x}}_k)$$

$$\Sigma_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}) \hat{\Sigma}_k$$

unde:  $\mathbf{K}_k$  este coeficientul lui Kalman la iterația  $k$ ;  $\mathbf{R}$  este covarianța zgomotului de măsurare (v. Eq.5.21); matricea  $\mathbf{H}$  este Jacobianul funcției  $\mathbf{h}$ , ea are rolul de adaptare dimensională;  $\mathbf{x}_k$  este starea estimată la iterația  $k$ ;  $\mathbf{z}_k$  este mărimea măsurată la pasul  $k$ ;  $(\mathbf{z}_k - \mathbf{H} \hat{\mathbf{x}}_k)$  este inovația;  $\Sigma_k$  este matricea de covarianță calculate la iterația  $k$ .





*Simulari*

Exemplul se referă la un RM modelat în ipoteze cinematice, care operează într-un mediu cunoscut, adică există mai multe marcaje ce pot fi identificate cu ajutorul senzorilor atașați RM. Putem afirma că dispunem de o hartă și putem imagina următoarele scenarii:

1. Robotul identifică fiecare marcaj și realizează măsurători relativ la fiecare dintre aceștia;
2. Robotul nu identifică cu precizie marcajele dar execută măsurători relative la fiecare marcaj (nu știe ce marcaj a generat măsurătorile realizate);
3. Robotul nu identifică cu precizie marcajele și execută măsurători într-un anumit domeniu (nu știe ce marcaj a generat măsurătorile realizate, iar măsurătorile sunt posibile doar într-un domeniu specific al senzorului.

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \\ \theta_{k+1} \end{bmatrix} = \begin{bmatrix} x_k \\ y_k \\ \theta_k \end{bmatrix} + \begin{bmatrix} -\frac{v}{\omega} \sin(\theta_k) + \frac{v}{\omega} \sin(\theta_k + \omega \Delta t) \\ \frac{v}{\omega} \cos(\theta_k) - \frac{v}{\omega} \cos(\theta_k + \omega \Delta t) \\ \omega \Delta t + \gamma \Delta t \end{bmatrix}$$

$$\omega = 0$$

$$x_{k+1} = x_k + v \cos(\theta_k) \Delta t$$

$$y_{k+1} = y_k + v \sin(\theta_k) \Delta t$$

$$\theta_{k+1} = \theta_k$$

$$\mathbf{F} = \begin{bmatrix} \frac{\partial x_{k+1}}{\partial x_k} & \frac{\partial x_{k+1}}{\partial y_k} & \frac{\partial x_{k+1}}{\partial \theta_k} \\ \frac{\partial y_{k+1}}{\partial x_k} & \frac{\partial y_{k+1}}{\partial y_k} & \frac{\partial y_{k+1}}{\partial \theta_k} \\ \frac{\partial \theta_{k+1}}{\partial x_k} & \frac{\partial \theta_{k+1}}{\partial y_k} & \frac{\partial \theta_{k+1}}{\partial \theta_k} \end{bmatrix} = \begin{bmatrix} 1 & 0 & -v \sin(\theta_k) \Delta t \\ 0 & 1 & v \cos(\theta_k) \Delta t \\ 0 & 0 & 1 \end{bmatrix}$$


$$\mathbf{G} = \begin{bmatrix} \frac{\partial x_{k+1}}{\partial v} & 0 \\ \frac{\partial y_{k+1}}{\partial v} & 0 \\ \frac{\partial \theta_{k+1}}{\partial v} & 0 \end{bmatrix} = \begin{bmatrix} \cos(\theta_k) \Delta t & 0 \\ \sin(\theta_k) \Delta t & 0 \\ 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \\ \theta_{k+1} \end{bmatrix} = \begin{bmatrix} x_k \\ y_k \\ \theta_k \end{bmatrix} + \begin{bmatrix} -\frac{v}{\omega} \sin(\theta_k) + \frac{v}{\omega} \sin(\theta_k + \omega \Delta t) \\ \frac{v}{\omega} \cos(\theta_k) - \frac{v}{\omega} \cos(\theta_k + \omega \Delta t) \\ \omega \Delta t + \gamma \Delta t \end{bmatrix}$$

$$\omega \neq 0$$

$$\mathbf{F} = \begin{bmatrix} \frac{\partial x_{k+1}}{\partial x_k} & \frac{\partial x_{k+1}}{\partial y_k} & \frac{\partial x_{k+1}}{\partial \theta_k} \\ \frac{\partial y_{k+1}}{\partial x_k} & \frac{\partial y_{k+1}}{\partial y_k} & \frac{\partial y_{k+1}}{\partial \theta_k} \\ \frac{\partial \theta_{k+1}}{\partial x_k} & \frac{\partial \theta_{k+1}}{\partial y_k} & \frac{\partial \theta_{k+1}}{\partial \theta_k} \end{bmatrix} = \begin{bmatrix} 1 & 0 & -\frac{v}{\omega} \cos(\theta_k) + \frac{v}{\omega} \cos(\theta_k + \omega \Delta t) \\ 0 & 1 & -\frac{v}{\omega} \sin(\theta_k) + \frac{v}{\omega} \sin(\theta_k + \omega \Delta t) \\ 0 & 0 & 1 \end{bmatrix}$$

$$\mathbf{G} = \begin{bmatrix} \frac{\partial x_{k+1}}{\partial v} & \frac{\partial x_{k+1}}{\partial \omega} \\ \frac{\partial y_{k+1}}{\partial v} & \frac{\partial y_{k+1}}{\partial \omega} \\ \frac{\partial \theta_{k+1}}{\partial v} & \frac{\partial \theta_{k+1}}{\partial \omega} \end{bmatrix} = \begin{bmatrix} \frac{1}{\omega} (-\sin(\theta_k) + \sin(\theta_k + \omega \Delta t)) & \frac{v}{\omega^2} (\sin(\theta_k) - \sin(\theta_k + \omega \Delta t)) + \frac{v}{\omega} (\cos(\theta_k + \omega \Delta t) \Delta t) \\ \frac{1}{\omega} (\cos(\theta_k) - \cos(\theta_k + \omega \Delta t)) & \frac{v}{\omega^2} (-\cos(\theta_k) - \cos(\theta_k + \omega \Delta t)) - \frac{v}{\omega} (\sin(\theta_k + \omega \Delta t) \Delta t) \\ 0 & \Delta t \end{bmatrix}$$



$$\boldsymbol{\delta} = \begin{bmatrix} \delta_x & \delta_y \end{bmatrix}^T = \begin{bmatrix} m_{j,x} - \mu_x & m_{j,y} - \mu_y \end{bmatrix}^T$$

$$q = \boldsymbol{\delta}^T \boldsymbol{\delta}$$

$$\mathbf{z}^i = \begin{bmatrix} \sqrt{q} \\ \tan^{-1}(\delta_y / \delta_x) - \mu_\theta \\ M_{j,s} \end{bmatrix}$$



$$\mathbf{H}_t^i = \begin{bmatrix} \frac{\partial z_1}{\partial x} & \frac{\partial z_1}{\partial y} & \frac{\partial z_1}{\partial \theta} \\ \frac{\partial z_2}{\partial x} & \frac{\partial z_2}{\partial y} & \frac{\partial z_2}{\partial \theta} \\ \frac{\partial z_3}{\partial x} & \frac{\partial z_3}{\partial y} & \frac{\partial z_3}{\partial \theta} \end{bmatrix} = \frac{1}{q} \begin{bmatrix} -\sqrt{q}\delta_x & -\sqrt{q}\delta_y & 0 \\ \delta_y & -\delta_x & -1 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} \sigma_x & 0 & 0 \\ 0 & \sigma_y & 0 \\ 0 & 0 & \sigma_\theta \end{bmatrix}$$

$$\mathbf{R}_t = \begin{bmatrix} \sigma_r & 0 & 0 \\ 0 & \sigma_\phi & 0 \\ 0 & 0 & \sigma_s \end{bmatrix}$$

$\delta=10[\text{m}]; \phi=\pi/4[\text{rad}]$ .

$\sigma_{r,\theta}=0.1$



- **Predicția**

$$1: \quad \hat{\boldsymbol{\mu}}_t = \boldsymbol{\mu}_{t-1} + \begin{bmatrix} -\frac{v_t}{\omega_t} \sin \mu_{t-1,\theta} + \frac{v_t}{\omega_t} \sin(\mu_{t-1,\theta} + \omega_t \Delta t) \\ \frac{v_t}{\omega_t} \cos \mu_{t-1,\theta} - \frac{v_t}{\omega_t} \cos(\mu_{t-1,\theta} + \omega_t \Delta t) \\ \omega_t \Delta t \end{bmatrix}$$

$$2: \quad \mathbf{F}_t = \begin{bmatrix} 1 & 0 & -\frac{v_t}{\omega_t} \cos \mu_{t-1,\theta} + \frac{v_t}{\omega_t} \cos(\mu_{t-1,\theta} + \omega_t \Delta t) \\ 0 & 1 & -\frac{v_t}{\omega_t} \sin \mu_{t-1,\theta} + \frac{v_t}{\omega_t} \sin(\mu_{t-1,\theta} + \omega_t \Delta t) \\ 0 & 0 & 1 \end{bmatrix}$$

$$3: \quad \hat{\boldsymbol{\Sigma}}_t = \mathbf{F}_t \cdot \boldsymbol{\Sigma}_{t-1} \cdot \mathbf{F}_t^T + \mathbf{G}_t \boldsymbol{\Sigma}_C \mathbf{G}_t^T$$

- Corecția

$$4: \mathbf{R}_t = \begin{bmatrix} \sigma_r & 0 & 0 \\ 0 & \sigma_\phi & 0 \\ 0 & 0 & \sigma_s \end{bmatrix}$$

5:

$$\begin{aligned} & \text{pentru\_toate\_marcajele\_} \mathbf{z}_t^i = \begin{bmatrix} r_t^i & \phi_t^i & s_t^i \end{bmatrix}^T \\ & \boldsymbol{\delta} = \begin{bmatrix} \delta_x & \delta_y \end{bmatrix}^T = \begin{bmatrix} m_{j,x} - \hat{\mu}_{t,x} & m_{j,y} - \hat{\mu}_{t,y} \end{bmatrix}^T \\ & q = \boldsymbol{\delta}^T \boldsymbol{\delta} \\ & \hat{\mathbf{z}}_t^i = \begin{bmatrix} \sqrt{q} \\ a \tan 2(\delta_y, \delta_x) - \bar{\mu}_{t,\theta} \\ m_{j,s} \end{bmatrix} \\ & \mathbf{H}_t^i = \frac{1}{q} \begin{bmatrix} -\sqrt{q}\delta_x & -\sqrt{q}\delta_y & 0 \\ \delta_y & -\delta_x & -1 \\ 0 & 0 & 0 \end{bmatrix} \\ & \mathbf{K}_t^i = \hat{\boldsymbol{\Sigma}}_t \cdot \mathbf{H}_t^{i,T} \left( \mathbf{H}_t^i \hat{\boldsymbol{\Sigma}}_t \mathbf{H}_t^{i,T} + \mathbf{R}_t \right)^{-1} \\ & \text{end} \end{aligned}$$


$$6: \boldsymbol{\mu}_t = \hat{\boldsymbol{\mu}}_t + \sum_i \mathbf{K}_t^i (\mathbf{z}_t^i - \hat{\mathbf{z}}_t^i)$$

$$7: \boldsymbol{\Sigma}_t = \left( \mathbf{I} - \sum_i \mathbf{K}_t^i \mathbf{H}_t^i \right) \cdot \hat{\boldsymbol{\Sigma}}_t$$

$$\{\boldsymbol{\mu}_t, \boldsymbol{\Sigma}_t\}$$


$$\Sigma_0 = \begin{bmatrix} 0.01 & 0 & 0 \\ 0 & 0.001 & 0 \\ 0 & 0 & 0.0001 \end{bmatrix} \quad v=1[\text{m/s}], w=0[\text{rad/sec}], \mu=[0,0,0]$$

Postura inițială este cunoscută cu acuratețe, după primii pași aceasta crește pentru că marcajele sunt în apropiere, apoi începe să scadă datorită faptului că marcajele sunt din ce în ce mai depărtate.




$$\Sigma_0 = \begin{bmatrix} 0.01 & 0 & 0 \\ 0 & 0.01 & 0 \\ 0 & 0 & 0.001 \end{bmatrix} \quad v=1[\text{m/s}], w=0[\text{rad/sec}], \mu=[-5,0,0]$$

Postura inițială este cunoscută cu mai puțină acuratețe, după primii pași aceasta crește pentru că marcajele sunt în apropiere, apoi începe să scadă din cauza faptului că marcajele sunt din ce în ce mai depărtate.




$$\Sigma_0 = \begin{bmatrix} 0.01 & 0 & 0 \\ 0 & 0.01 & 0 \\ 0 & 0 & 0.001 \end{bmatrix} \quad v=1[\text{m/s}], w=0.25[\text{rad/sec}], \mu=[0,0,0]$$

Postura inițială este cunoscută cu mai puțină acuratețe, după primii pași ea crește pentru că marcajele sunt în apropiere, apoi începe să scadă datorită faptului că marcajele sunt din ce în ce mai depărtate, la final RM se apropie din nou de marcaje, ceea ce conduce la creșterea acurateței.



$$\Sigma_0 = \begin{bmatrix} 0.01 & 0 & 0 \\ 0 & 0.001 & 0 \\ 0 & 0 & 0.0001 \end{bmatrix} \quad v=1[\text{m/s}], w=0.25[\text{rad/sec}], \mu=[0,0,0]$$

Postura inițială este cunoscută cu acuratețe și se modifică în funcție de poziția relativă a RM față de marcaje.






Concluzii

EKF este o variantă a filtrului Kalman, care permite a **daptarea acestuia pentru sisteme neliniare**. În cazul în care neliniaritatea nu este severă, atunci există o vecinătate a stării curente unde formalismul original poate fi adaptat.

Această transformare constă în determinarea unor matrice de inerție, de comandă și de ieșire aproximative, ce pot fi utilizate ca substitut. **Aceste matrice sunt Jacobienele funcțiilor neliniare din spațiul stărilor.**

Cele două etape ale filtrului Kalman se păstrează în următorul sens:

- **Predicția** calculează valoarea estimată a vectorului de stare cu ajutorul **modelului neliniar**, iar valoarea matricei de covarianță apelează la **Jacobianul aceste funcții neliniare**;
- **Corecția** calculează coeficientul lui Kalman, starea și matricea de covarianță cu ajutorul matricelor Jacobian corespunzătoare funcțiilor de ieșire.



Filtrul de Particule

1. Introducere


2. Formalism

3. Simulări


4. Concluzii

Filtrul de Particule (metoda propusă de Del Moral în 1996) sau metoda Secvențială Monte Carlo (propusă de Liu și Chang în 1998) **permite eludarea ipotezelor** necesare **filtrului Kalman**.


Față de filtrul Bayesian, care la rândul lui nu necesită aceste ipoteze, filtrul de particule se **focalizează pe domeniile importante** și nu pe întregul spațiu al ale vectorilor de stare



- a. **Este faza inițială**, deasupra axei orizontale care arată calea de rulare este desenat RM, alături de trei marcaje  $M_{1,...,3}$ . **RM realizează o măsurătoare, notată cu  $z_1$**  relativ la primul marcaj. Sub axa orizontală este ilustrată distribuția de probabilitate  $bel_0$ . **Fiind o fază inițială, distribuția de probabilitate este uniformă**, adică RM poate fi în oricare din pozițiile marcate cu linii verticale, cu aceeași probabilitate. Liniile menționate reprezintă un eșantionaj al domeniului continuu (calea de rulare);
- b. **Din fiecare punct de eșantionare se realizează măsurători (cu zgomot) către marcajele  $M_i$** . Măsurătorile sunt apoi ordonate în funcție de modul în care aproximează măsurătoarea  $z_1$  a RM. **Fiecărui eșantion i se asociază o valoare care exprimă calitatea aproximării**. Eșantioanele cu cele mai bune aproximări sunt asociate cu valori  $w_j$  mai mari. Acest parametru este denumit importanța eșantionului. Utilizând acest parametru se realizează o reeșantionare, aleatoare **după o distribuție normală a valorii de eșantionare  $w_j$** ;




- c. Prezintă rezultatul reeșantionării. Deși, în final, numărul de eșantioane din faza a și c sunt aceleași, aceasta din urmă cuprinde **puncte care au fost alese de mai multe ori**. Schița subliniază acest fenomen prin utilizarea unei hașuri mai dese. Apar însă și zone albe, de unde nu au fost alese eșantioane. **Acest fenomen este definitiv filtrului, faptul că distribuția de probabilitate începe să se concentreze pe anumite zone;**
- d. Reprezintă o succesiune de 2 faze. Prima este comanda RM cu mărimea  $u$  (aici o translație de lungime  $u$ ), concomitentă cu **comanda tuturor eșantioanelor cu mărimea de comandă  $u$** . Comenzile sunt însoțite de perturbațiile modelului, astfel încât chiar dacă în faza c existau multe eșantioane identice, **după această comandă ele vor deveni distincte**. A doua în care RM și eșantioanele realizează o nouă măsurătoare similar fazei b;
- e. Procesul continuă cu o reeșantionare similară celei b. Schița prezintă rezultatul aceste fazei;




**Predicția** în care RM și eșantioanele primesc comanda  $u_i$ , fapt ce conduce la o nouă poziție estimată  $\mu_i$  a RM și la o nouă distribuție de probabilitate estimată  $bel_i$ ;

**Corecția** în care RM și eșantioanele măsoară mărimea  $z_i$ , respectiv pozițiile eșantioanelor vizavi de senzori. Acestea din urmă sunt comparate și ordonate în conformitate cu cât de bine aproximează măsurătoarea RM  $z_i$  (apare astfel conceptul calitativ  $w_j$ ). Mulțimea ordonată devine obiectul unei reeșantionări normalizate, unde cele mai bune eșantioane (cele cu valoare mare  $w_j$ ) sunt favorizate să fie alese de mai multe ori. Se obține astfel o nouă distribuție de probabilitate  $bel_i$  care conduce la o poziție corectată




*Simulari*


Inițial: postura robotului, considerată a fi necunoscută, este  $[0;30;\pi]$  ; cele 4 marcaje ilustrate prin cruci albastre  $[\pm 50; \pm 50]$  ; și mulțimea particulelor aflate într-o distribuție uniformă




Începem cu corecția care selectează cele mai potrivite particule, a căror postură permite calculul posturi RM



Predicția constă în deplasarea RM și a norului de particule pe baza unui model acceptat (aici 5.47) și care cuprinde perturbațiile referitoare la cele trei mișcări ale RM  $[\Theta, r, y]$



Ciclul Corecție-Predicție este executat de un anumit număr de ori. RM este reprezentat printr-un cerc verde; pozițiile sale anterioare sunt desenate prin cercuri maro iar postura estimată prin simbolul \*. Pentru a asigura o mai mare claritate a imaginii s-a decis ca în figură să nu apară roiul (norul) de Particule.





Concluzii

Filtrul de Particule face parte din familia filtrelor Bayesien. Este un ciclu compus din două etape: Predicție și Corecție.

**Predicția** apelează la un model acceptat pe care îl utilizează la **iterarea stării RM și a Particulelor (eșantioanelor)**. **Corecția** este, în fapt, o reeșantionare a spațiului stărilor, în funcție de performanțele acestora în aproximarea măsurătorilor realizate de RM.

Reeșantionarea se face, din mulțimea eșantioanelor inițiale, prin alegerea după o distribuție Gaussiană, care **favorizează performanța** menționată. Chiar dacă un eșantion (performant) este ales de mai multe ori, mulțimea particulelor rămâne neschimbată.

Exemplarele identice **devin diferite** în momentul predicției, **datorită perturbațiilor** aleatoare.

Cele două etape menționate nu utilizează ipotezele filtrului Kalman ci operează cu cazuri generale. Față de ***filtrele parametrice (Kalman și EKF) volumul de calcul este mai mare,***

*Față de filtrul Bayesian, datorită unei eșantionări speciale, acest volum este mai mic.*

| Capitolul | Modelare |  |  | Traectorii |  | Senzori | Localizare |    |  | Conducere |    | SLAM |  |  |
|-----------|----------|--|--|------------|--|---------|------------|----|--|-----------|----|------|--|--|
| Săptămâna | 9        |  |  | 10a        |  | 10b     | 11         | 12 |  | 13        | 14 |      |  |  |